
TP 2.2 — GENERADORES DE NÚMEROS PSEUDOALEATORIOS DE DISTINTAS DISTRIBUCIONES DE PROBABILIDAD

19 de junio de 2026

Tomás Andino

LEG: 52995

tomasandino12@gmail.com

Agustín Barroso Bollero

LEG: 52818

agusbarrosobollero@gmail.com

Facundo Gregoret

LEG: 52634

gregoretfacu18@gmail.com

Gerónimo Negri

LEG: 52991

geronimonegri@gmail.com

Bruno Schiffó

LEG: 53256

schiffobruno2233@gmail.com

Universidad Tecnológica Nacional — Facultad Regional Rosario

Zeballos 1341, S2000, Rosario, Argentina

Materia: Simulación — Año 2026

ABSTRACT

El presente trabajo extiende el estudio de los números pseudoaleatorios iniciado en el trabajo práctico anterior, abordando la generación de variables aleatorias con distintas distribuciones de probabilidad a partir de un generador uniforme en $[0, 1]$. Se estudian e implementan en Python 3 generadores para nueve distribuciones —tanto continuas como discretas— siguiendo la metodología propuesta por Thomas Naylor en *Técnicas de Simulación en Computadoras* (1982). Para cada distribución se desarrolla el fundamento teórico, se describe el método de generación empleado (transformada inversa y método de rechazo donde corresponde), y se verifica el correcto funcionamiento mediante testeo estadístico y visualizaciones gráficas (si corresponde).

Keywords Simulación · Números pseudoaleatorios · Distribuciones de probabilidad · Transformada inversa · Método de rechazo · Python

1. Introducción

1.1. Contexto y objetivos del trabajo

En el trabajo práctico anterior se estudió la generación de números pseudoaleatorios y se verificó su calidad mediante distintos tests estadísticos. El resultado fue un generador capaz de producir valores distribuidos uniformemente en el intervalo $[0, 1]$. Sin embargo, la mayoría de los fenómenos que se desean simular no siguen una distribución uniforme: los tiempos de llegada de clientes, la cantidad de fallas en un sistema, o los errores de medición, entre otros, responden a distribuciones muy diversas.

Surge entonces la pregunta: dado que contamos con un generador de números uniformes entre 0 y 1, ¿cómo podemos utilizarlo para generar valores que sigan otras distribuciones de probabilidad?

El objetivo de este trabajo es definir e implementar generadores de variables aleatorias para distintas distribuciones de probabilidad, tanto continuas como discretas, siguiendo la metodología propuesta por Thomas Naylor en *Técnicas*

de Simulación en Computadoras (1). Para cada distribución se desarrollará su fundamento teórico, y se definirán matemáticamente. Finalmente, se implementarán algunas al lenguaje Python 3 y se realizarán tests sobre estas.

2. Marco Teórico General

2.1. Distribuciones de probabilidad continuas

Una variable aleatoria es continua cuando puede tomar cualquier valor dentro de un intervalo, incluyendo todos los decimales posibles entre dos puntos. Esto implica que el conjunto de valores posibles es infinito e incontable.

Para una variable aleatoria continua X , la probabilidad se describe mediante su función de densidad de probabilidad $f(x)$, que satisface las siguientes propiedades:

- $f(x) \geq 0$ para todo x .
- El área total bajo la curva es igual a 1: $\int_{-\infty}^{+\infty} f(x) dx = 1$.
- La probabilidad de que X tome un valor en el intervalo $[a, b]$ es el área bajo la curva entre a y b : $P(a \leq X \leq b) = \int_a^b f(x) dx$.

Es importante destacar que para una variable continua, la probabilidad de que tome un valor límite exacto es cero. Solo tiene sentido hablar de probabilidad sobre intervalos abiertos.

La función de distribución acumulada $F(x)$ se define como:

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt. \quad (1)$$

Esta función es creciente, va de 0 a 1, y representa la probabilidad acumulada hasta el valor x . Entre las distribuciones continuas más utilizadas en simulación se encuentran la uniforme, la exponencial, la gamma y la normal, todas estudiadas en este trabajo.

2.2. Distribuciones de probabilidad discretas

Una variable aleatoria es discreta cuando solo puede tomar valores enteros y contables. El conjunto de valores posibles es finito o infinito numerable $(0, 1, 2, 3, \dots)$.

Para una variable aleatoria discreta X , la probabilidad se describe mediante su función de probabilidad $f(x)$, definida como:

$$f(x) = P(X = x).$$

Esta función satisface:

- $f(x) \geq 0$ para todo x .
- La suma de todas las probabilidades es 1: $\sum_x f(x) = 1$.

La función de distribución acumulada para el caso discreto se define como:

$$F(x) = P(X \leq x) = \sum_{k \leq x} f(k). \quad (2)$$

A diferencia del caso continuo, $F(x)$ es una función escalonada que sube en los valores enteros donde hay probabilidad positiva.

Las distribuciones discretas son especialmente útiles en simulación cuando se modela la ocurrencia de eventos contables: cantidad de llegadas, número de fallas, demanda de productos, entre otros. En este trabajo se estudian las distribuciones de Pascal, Binomial, Hipergeométrica, Poisson y Empírica Discreta.

2.3. Métodos de generación: Transformada Inversa y Método de Rechazo

2.3.1. Método de la Transformada Inversa

El método de la transformada inversa es la técnica para generar valores de cualquier distribución a partir de números pseudoaleatorios uniformes entre 0 y 1.

La idea se basa en una propiedad clave: la función de distribución acumulada $F(x)$ siempre toma valores en el intervalo $[0, 1]$, exactamente el mismo rango que los números pseudoaleatorios r que ya sabemos generar.

El procedimiento es el siguiente:

1. Se genera un número pseudoaleatorio r con distribución uniforme en $[0, 1]$.
2. Se iguala $r = F(x)$ y se despeja x , obteniendo $x = F^{-1}(r)$.
3. El valor x obtenido sigue la distribución deseada.

Matemáticamente, esto se justifica porque si $r = F(x)$, entonces $x = F^{-1}(r)$ y puede demostrarse que x tiene exactamente la función de densidad $f(x)$ buscada.

El método es directo y eficiente cuando $F(x)$ tiene una expresión analítica invertible. Cuando esto no es posible (como en la distribución normal o gamma) se recurre a aproximaciones o métodos alternativos.

2.3.2. Método de Rechazo

El método de rechazo se utiliza cuando la función de densidad $f(x)$ tiene un rango finito, es decir, cuando $a \leq x \leq b$. Los pasos del método son:

1. Normalizar el rango de f mediante una constante c tal que $c \cdot f(x) \leq 1$ para todo $x \in [a, b]$.
2. Generar una pareja de números aleatorios (r_1, r_2) .
3. Calcular el candidato $x = a + (b - a) \cdot r_1$.
4. Si $r_2 \leq c \cdot f(x)$, aceptar x como valor generado. En caso contrario, rechazar y volver al paso 2.

La eficiencia del método depende de cuántas parejas deben generarse antes de encontrar una aceptada. Naylor demuestra que la esperanza matemática del número de intentos es igual a $1/c$. Si c es muy pequeño (la función está muy concentrada respecto al rango total), el método puede volverse muy ineficiente.

3. Distribuciones Continuas

3.1. Distribución Uniforme

3.1.1. Definición teórica y parámetros

La distribución uniforme es la función de densidad de probabilidad más simple. Se caracteriza porque la probabilidad está distribuida de manera constante en todo el intervalo (a, b) , siendo cero fuera de él. Esta distribución surge al estudiar, por ejemplo, los errores de redondeo al registrar medidas con cierta precisión.

Parámetros: a (límite inferior) y b (límite superior), con $a < b$.

Función de densidad:

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } a < x < b, \\ 0 & \text{fuera del intervalo } (a, b). \end{cases} \quad (3)$$

Función de distribución acumulada:

$$F(x) = \frac{x-a}{b-a}, \quad a \leq x \leq b. \quad (4)$$

Valor esperado y varianza:

$$EX = \frac{a+b}{2}, \quad VX = \frac{(b-a)^2}{12}. \quad (5)$$

En muchos casos prácticos no se conocen directamente a y b , sino la media y la varianza del fenómeno a simular. En ese caso es posible despejar los parámetros:

$$a = EX - \sqrt{3 \cdot VX}, \quad b = 2 \cdot EX - a. \quad (6)$$

3.1.2. Transformada Inversa

Dado que $F(x) = (x - a)/(b - a)$ tiene una expresión explícita e invertible, se puede aplicar directamente el método de la transformada inversa. Igualando $F(x) = r$ y despejando x :

$$r = \frac{x - a}{b - a}$$

$$x = a + (b - a) \cdot r, \quad 0 \leq r \leq 1.$$

Esto significa que para generar un valor con distribución uniforme en (a, b) , alcanza con generar un número pseudo-aleatorio r y aplicar la fórmula anterior.

Ejemplo numérico: si $a = 2$, $b = 8$ y $r = 0,6$, entonces:

$$x = 2 + (8 - 2) \cdot 0,6 = 2 + 3,6 = 5,6.$$

3.1.3. Método de Rechazo

Para la distribución uniforme, la función de densidad $f(x) = 1/(b - a)$ es constante en todo el intervalo. Al aplicar el método de rechazo con $c = b - a$ (de modo que $c \cdot f(x) = 1$), cualquier par de números aleatorios generados cumple la condición de aceptación. Por este motivo, el método de rechazo no tiene ventajas prácticas sobre la transformada inversa para esta distribución; sin embargo, es útil como caso ilustrativo del método general.

3.1.4. Implementación en Python

La implementación en Python (o en cualquier lenguaje de programación) de la distribución uniforme es bastante simple y se hace en un par de líneas. En el anterior informe hablamos de que los lenguajes de programación cuentan con un generador uniforme de números aleatorios entre 0 y 1 a los que llamaremos r , pero si queremos generalizar para todas las distribuciones uniformes de intervalo (a, b) cuyo resultado da una variable aleatoria x , tendremos que asignar cada r a uno y un solo valor de x . Sin muchos rodeos, aplicaremos la transformada inversa. Es fácil de demostrar que si queremos utilizar un intervalo $(0, 1)$, sucede que $x = r$.

```
1 def distribucion_uniforme(a, b):
2     r = random.random()
3     x = a + (b-a) * r
4     return x
```

3.1.5. Testeo y resultados

Se generaron 1000 muestras con el método utilizando $a = 4$ y $b = 8$, correspondientes a una distribución $X \sim U(4, 8)$. Nuestros tests verifican que tienen sentido los resultados, ya que el error que se presenta es ínfimo y debe estar causado por el tamaño de la muestra.

	Teórico		Muestral	
Media (EX)	6,0000	5,9859	(error: 0,23 %)	
Varianza (VX)	1,3333	1,3293	(error: 0,30 %)	

Cuadro 1: Comparación de momentos — Uniforme($a = 4$, $b = 8$), $n = 1000$.




Figura 1: Histograma de frecuencias observadas — Uniforme($a = 4$, $b = 8$).

En el histograma se observa que la distribución tiende al rectángulo que se presenta en su función de densidad que vemos acá debajo, aunque por el tamaño de la muestra no es obvio. Aunque no tenga su forma característica, vemos que la media muestral y la teórica son coincidentes (con un error ínfimo del 0,23 %). Podemos decir que la implementación generó muestras compatibles con una distribución uniforme de intervalo (a, b) .




Figura 2: Función de densidad teórica de la distribución uniforme.

3.2. Distribución Exponencial

3.2.1. Definición teórica y parámetros

La distribución exponencial modela el tiempo entre ocurrencias sucesivas de eventos aleatorios independientes. Es decir, describe cuánto tiempo transcurre entre un evento y el siguiente en un proceso donde los eventos ocurren de forma continua e independiente entre sí. Ejemplos típicos son: el tiempo entre llegadas de clientes a una cola, el intervalo entre accidentes en una fábrica, el tiempo entre aterrizajes de aviones en un aeropuerto, o el tiempo entre llegadas de pedidos a una empresa.

Para que una variable aleatoria X siga una distribución exponencial, deben cumplirse las siguientes condiciones:

1. La probabilidad de que ocurra un evento en un intervalo corto $[t, t + \Delta t]$ es aproximadamente $\alpha \cdot \Delta t$.
2. α es una constante que no depende del tiempo t ni de ningún otro factor.

3. La probabilidad de que ocurran dos o más eventos en ese intervalo tiende a cero a medida que $\Delta t \rightarrow 0$.

Parámetro: α (alfa), con $\alpha > 0$. Representa la tasa de ocurrencia de eventos por unidad de tiempo.

Función de densidad:

$$f(x) = \alpha e^{-\alpha x}, \quad x \geq 0. \quad (7)$$

Función de distribución acumulada:

$$F(x) = 1 - e^{-\alpha x}, \quad x \geq 0. \quad (8)$$

Valor esperado y varianza:

$$EX = \frac{1}{\alpha}, \quad VX = \frac{1}{\alpha^2} = (EX)^2. \quad (9)$$

Nótese que la varianza es igual al cuadrado de la media. Como α es el único parámetro de la distribución, puede expresarse directamente en función de la media conocida:

$$\alpha = \frac{1}{EX}. \quad (10)$$

3.2.2. Transformada Inversa

Dado que $F(x) = 1 - e^{-\alpha x}$ tiene una expresión explícita, es posible aplicar el método de la transformada inversa. Igualando $F(x) = r$ y despejando x :

$$r = 1 - e^{-\alpha x}.$$

Aprovechando la simetría entre $F(x)$ y $1 - F(x)$ en la distribución uniforme, se puede reemplazar r por $1 - r$ sin alterar la distribución del resultado. Esto simplifica la expresión:

$$\begin{aligned} r &= e^{-\alpha x} \\ \ln(r) &= -\alpha x \\ x &= -\frac{1}{\alpha} \ln(r) = -EX \cdot \ln(r). \end{aligned}$$

Por lo tanto, para generar un valor con distribución exponencial de media EX , basta con generar un número pseudo-aleatorio r y aplicar:

$$x = -EX \cdot \ln(r). \quad (11)$$

Ejemplo numérico 1: si $EX = 3$ (es decir, $\alpha = 1/3$) y $r = 0,25$:

$$x = -3 \cdot \ln(0,25) = -3 \cdot (-1,386) = 4,16.$$

Ejemplo numérico 2: si $EX = 5$ y $r = 0,70$:

$$x = -5 \cdot \ln(0,70) = -5 \cdot (-0,357) = 1,78.$$

3.2.3. Método de Rechazo

El método de rechazo no se aplica a la distribución exponencial en la bibliografía de Naylor, dado que la transformada inversa provee una solución directa, exacta y computacionalmente eficiente. Sin embargo, Naylor menciona como dato de interés histórico que Von Neumann propuso un método de rechazo para esta distribución, el cual evita el cálculo del logaritmo natural. Dicho método resulta más rápido en ciertos contextos de programación, aunque su implementación es considerablemente más compleja. Para los fines de este trabajo se utiliza exclusivamente la transformada inversa.

3.2.4. Testeo y resultados

3.3. Distribución Gamma

3.3.1. Definición teórica y parámetros

La distribución gamma modela el tiempo total transcurrido para un proceso compuesto por k eventos sucesivos, siendo el resultado equivalente a la suma de k valores independientes de variables aleatorias con distribución exponencial y

parámetro α . Cuando el parámetro k toma el valor de un número entero positivo, recibe el nombre de distribución de Erlang. La distribución de Erlang consiste en el producto de k distribuciones exponenciales.

La forma generalizada de la distribución gamma se obtiene permitiéndole al parámetro k adoptar valores positivos sin la restricción de ser enteros.

Comportamiento asintótico y relacional:

- En el caso específico donde $k = 1$, la distribución gamma resulta idénticamente igual a la distribución exponencial.
- A medida que el valor del parámetro k se incrementa, la curva de la distribución gamma tiende de forma asintótica hacia una distribución normal.

Parámetros:

- α : Parámetro de escala, es estrictamente positivo ($\alpha > 0$).
- k : Parámetro de forma, es estrictamente positivo ($k > 0$).
- x : Valor de la variable aleatoria.

Función de densidad:

$$f(x) = \frac{\alpha^k x^{(k-1)} e^{-\alpha x}}{(k-1)!}$$

Valor esperado y varianza:

$$EX = \frac{k}{\alpha}, \quad VX = \frac{k}{\alpha^2}$$

A diferencia del modelo exponencial, en la distribución gamma los parámetros del modelo pueden determinarse analíticamente si se conocen la media y la varianza empíricas del sistema:

$$\alpha = \frac{EX}{VX}, \quad k = \frac{(EX)^2}{VX}$$

3.3.2. Transformada Inversa

La distribución gamma no admite el uso del método directo de la transformada inversa. La estrategia principal para generar valores de esta variable, cuando k es entero (caso Erlang), consiste en calcular la suma de k valores generados mediante transformadas inversas de la distribución exponencial.

La expresión matemática es:

$$x = \sum_{i=1}^k x_i = -\frac{1}{\alpha} \sum_{i=1}^k \ln(r_i)$$

Aplicando las propiedades logarítmicas, la fórmula se simplifica a un único logaritmo aplicado sobre la productoria de los números pseudoaleatorios, obteniendo la siguiente forma optimizada:

$$x = -\frac{1}{\alpha} \ln \left(\prod_{i=1}^k r_i \right)$$

Generar valores para la distribución gamma cuando el parámetro k no es un número entero sigue siendo un problema matemático sin una solución exacta en simulación. Sin embargo, existe un método de aproximación:

La idea principal es 'partir' el número. Si k es mayor a 1 pero tiene decimales, lo dividimos en su parte entera (k_1) y su parte decimal (q). Esto se expresa como $k = k_1 + q$ (donde $0 < q < 1$). Definimos al número entero inmediatamente superior como k_2 (es decir, $k_2 = k_1 + 1$).

Como el algoritmo computacional no sabe procesar el número con decimales directamente, vamos a alternar aleatoriamente entre los dos números enteros que rodean a k :

- Se genera un valor utilizando el parámetro superior (k_2) con una probabilidad igual a q .
- Se genera un valor utilizando el parámetro inferior (k_1) con una probabilidad igual a $1 - q$.

Cuanto más grande sea el valor original de k , más exactos y satisfactorios serán los resultados de esta aproximación.

3.4. Distribución Normal

3.4.1. Definición y justificación teorica (Teorema Central del Limite)

La distribución normal es la más conocida y ampliamente utilizada de todas las distribuciones de probabilidad. Su popularidad se debe a dos razones principales. En primer lugar, las pruebas matemáticas señalan que bajo ciertas condiciones de calidad resulta justificado esperar una distribución normal, mientras que la experiencia estadística muestra que muchas distribuciones se aproximan a ella. En segundo lugar, su utilidad práctica radica en el teorema del límite central.

Este teorema postula que la distribución de probabilidad de la suma de N valores de variable aleatoria x_i independientes e idénticamente distribuidos, con medias μ_i y varianzas σ_i^2 , se aproxima asintóticamente a una distribución normal a medida que N crece, con media y varianza dadas por:

$$\mu = \sum_{i=1}^N \mu_i \quad (12)$$

$$\sigma^2 = \sum_{i=1}^N \sigma_i^2 \quad (13)$$

En consecuencia, el teorema del límite central permite el empleo de distribuciones normales para representar medidas globales operadas sobre los efectos de causas aditivas distribuidas en forma independiente, sin importar la distribución de probabilidad a que obedezcan las mediciones de causas individuales. El carácter que se atribuye a esta forma de interpretación del teorema del límite central resulta de particular importancia, ya que de esta manera se provee una justificación matemática para manipular la evidencia empírica.

3.4.2. Función de Densidad

Si la variable aleatoria X tiene una función de densidad $f(x)$ dada por:

$$f(x) = \frac{1}{\sigma_x \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{x - \mu_x}{\sigma_x} \right)^2}, \quad -\infty < x < \infty \quad (14)$$

con σ_x positiva, entonces se dice que X tiene una distribución normal o Gaussiana con parámetros μ_x y σ_x . La gráfica de esta función tiene la conocida forma de campana, simétrica respecto a μ_x .




Figura 3: Función de densidad de la distribución normal con parámetros μ y σ .

3.4.3. Distribución Normal Estandar

Cuando los parámetros toman los valores $\mu_x = 0$ y $\sigma_x = 1$, la función de densidad recibe el nombre de distribución normal estándar, con función de densidad:

$$f(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2}, \quad -\infty < z < \infty \quad (15)$$

Cualquier distribución normal puede convertirse a la forma estándar mediante la sustitución:

$$z = \frac{x - \mu_x}{\sigma_x} \quad (16)$$

3.4.4. Media y Varianza

El valor esperado y la varianza de una variable aleatoria con distribución normal están dados por:

$$EX = \mu_x \quad (17)$$

$$VX = \sigma_x^2 \quad (18)$$

donde μ_x representa la media de la distribución y σ_x^2 su varianza.

3.4.5. Función de distribución acumulativa

La función de distribución acumulativa de una variable aleatoria con distribución normal se define como:

$$F(x) = P(X \leq x) = \int_{-\infty}^x \frac{1}{\sigma_x \sqrt{2\pi}} e^{-\frac{(t-\mu_x)^2}{2\sigma_x^2}} dt \quad (19)$$

En el caso particular de la distribución normal estándar ($\mu_x = 0$ y $\sigma_x = 1$), la expresión anterior se reduce a:

$$\Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt \quad (20)$$

A diferencia de otras distribuciones estudiadas, esta integral no puede expresarse mediante funciones elementales. Por este motivo, la función acumulativa normal se encuentra tabulada y no posee una expresión inversa analítica cerrada.

Debido a esta característica, no es posible aplicar directamente el método de la transformada inversa, por lo que deben emplearse procedimientos alternativos para la generación de valores con distribución normal.

3.4.6. Método de la transformada inversa (procedimiento del límite central, $K = 12$)

Para simular una distribución normal con media μ_x y varianza σ_x^2 , se hace uso del Teorema del Límite Central aplicado a la suma de K variables aleatorias uniformes $r_1, r_2, \dots, r_K$ definidas en el intervalo $(0, 1)$, cada una de las cuales posee la misma distribución de probabilidad caracterizada por

$$E(r_i) = \theta$$

y

$$\text{Var}(r_i) = \sigma^2.$$

Para la distribución uniforme en este intervalo se tiene:

$$\theta = \frac{a+b}{2} = \frac{0+1}{2} = \frac{1}{2},$$

$$\sigma = \frac{b-a}{\sqrt{12}} = \frac{1}{\sqrt{12}}.$$

Por lo tanto, el valor de la variable aleatoria normal estandarizada Z queda:

$$Z = \frac{\sum_{i=1}^K r_i - \frac{K}{2}}{\sqrt{\frac{K}{12}}}.$$

Igualando con la expresión de estandarización

$$Z = \frac{x - \mu_x}{\sigma_x},$$

y resolviendo para x :

$$\frac{x - \mu_x}{\sigma_x} = \frac{\sum_{i=1}^K r_i - \frac{K}{2}}{\sqrt{\frac{K}{12}}},$$

$$x = \sigma_x \sqrt{\frac{12}{K}} \left(\sum_{i=1}^K r_i - \frac{K}{2} \right) + \mu_x.$$

En la práctica se recomienda $K = 12$ como valor mínimo deseable. Sin embargo, este método trunca la distribución aproximadamente a los límites $\pm 6\sigma$ y no resulta confiable para valores de x superiores a tres desviaciones estándar respecto de la media. Para obtener una mayor precisión pueden emplearse valores más altos, por ejemplo $K = 24$.

3.4.7. Método de rechazo (Von Neumann)

Sea $f(x)$ la función de densidad de la distribución normal estándar y sea $g(x)$ una función de densidad auxiliar tal que existe una constante $c > 0$ para la cual se cumple:

$$c \cdot g(x) \geq f(x) \quad \forall x \quad (21)$$

Entonces es posible generar valores de $f(x)$ mediante el siguiente procedimiento: se generan valores desde $g(x)$ y se aceptan con probabilidad $f(x)/(c \cdot g(x))$.

Dado que la distribución normal es simétrica, basta con considerar la mitad positiva. La función de densidad de la normal estándar restringida a $x > 0$ es:

$$f(x) = \sqrt{\frac{2}{\pi}} e^{-x^2/2}, \quad x > 0 \quad (22)$$

Se elige como función envoltura la distribución exponencial de media 1:

$$g(x) = e^{-x}, \quad x > 0 \quad (23)$$

Se puede demostrar que con $c = \sqrt{2e/\pi}$ se cumple $c \cdot g(x) \geq f(x)$ para todo $x > 0$, por lo que la exponencial constituye una envoltura válida.

La probabilidad de aceptación de un candidato y es:

$$P(\text{aceptar} \mid y) = \frac{f(y)}{c \cdot g(y)} = \frac{\sqrt{2/\pi} \cdot e^{-y^2/2}}{\sqrt{2e/\pi} \cdot e^{-y}} = e^{-(y^2/2 - y + 1/2)} = e^{-(y-1)^2/2} \quad (24)$$

Por lo tanto se acepta y si un valor uniforme $r_2 \in (0, 1)$ cumple:

$$r_2 \leq e^{-(y-1)^2/2} \quad (25)$$

1. Generar $r_1 \sim U(0, 1)$ y obtener un candidato exponencial: $y = -\ln r_1$
2. Generar $r_2 \sim U(0, 1)$
3. Si $r_2 \leq e^{-(y-1)^2/2}$ aceptar y , de lo contrario volver al paso 1
4. Generar $r_3 \sim U(0, 1)$ y asignar signo:

$$x = \begin{cases} +y & \text{si } r_3 \leq 0,5 \\ -y & \text{si } r_3 > 0,5 \end{cases} \quad (26)$$

El valor x resultante sigue una distribución normal estándar $\mathcal{N}(0, 1)$.

La probabilidad de aceptación en cada intento es:

$$P(\text{aceptar}) = \frac{1}{c} = \sqrt{\frac{\pi}{2e}} \approx 0,7602 \quad (27)$$

3.4.8. Procedimiento directo

Sean r_1 y r_2 dos valores de variable aleatoria independientes distribuidos uniformemente en el intervalo $(0, 1)$. Entonces:

$$x_1 = (-2 \log_e r_1)^{1/2} \cos 2\pi r_2 \quad (28)$$

$$x_2 = (-2 \log_e r_1)^{1/2} \sin 2\pi r_2 \quad (29)$$

son dos valores de variable aleatoria obtenidos a partir de una distribución normal estándar.

La idea proviene de la geometría. Si se toman dos variables normales estándar independientes z_1 y z_2 y se convierten a coordenadas polares, se observa que:

- El ángulo θ se distribuye uniformemente en $[0, 2\pi)$
- El radio $r = \sqrt{z_1^2 + z_2^2}$ sigue una distribución conocida

Box y Muller invirtieron el proceso: en lugar de partir de z_1 y z_2 para obtener r y θ , parten de dos uniformes para construir r y θ directamente, y de ahí recuperan dos valores normales. Con este método se logran resultados exactos y su velocidad de cómputo es comparable a la del método del límite central.

3.4.9. Procedimiento rápido

Este método genera las desviaciones aleatorias normales a partir de la mezcla de tres densidades:

$$f(x) = 0,9578 g_1(x) + 0,0395 g_2(x) + 0,0027 g_3(x) \quad (30)$$

El método proviene de una observación práctica: el 95 % de los valores de una normal estándar caen entre -2 y 2 . Marsaglia propone entonces dividir la generación en tres casos:

- Para ese 95 % se utiliza una tabla precomputada muy simple (g_1)
- Para el 4 % siguiente se emplea una función un poco más compleja (g_2)
- Para el 0.27 % restante, correspondiente a las colas, se utiliza la función más precisa (g_3)

De esta manera se evita calcular logaritmos y cosenos la mayor parte del tiempo, que son operaciones costosas computacionalmente.

3.4.10. Implementación en Python

Se implementaron dos funciones para la generación de valores con distribución normal: una basada en el procedimiento del límite central y otra basada en el método de rechazo de Von Neumann.

Transformada inversa (límite central, $K = 12$)

```
1 def distribucion_normal_limite_central(EX, VX):
2     STDV = sqrt(VX)
3     suma = sum(random.random() for _ in range(12))
4     return STDV * (suma - 6) + EX
```

Método de rechazo (Von Neumann)

```
1 def distribucion_normal_von_neumann(EX, VX):
2     STDV = sqrt(VX)
3     aceptado = False
4     while not aceptado:
5         r1 = random.random()
6         r2 = random.random()
7         y = -log(r1)
8         aceptado = r2 <= exp(-(y - 1)**2 / 2)
9     r3 = random.random()
10    if r3 <= 0.5:
11        z = y
12    else:
13        z = -y
14    return STDV * z + EX
```

3.4.11. Testeo y resultados

Se generaron 1000 muestras con cada método utilizando los parámetros $EX = 0$ y $VX = 1$, correspondientes a la distribución normal estándar $\mathcal{N}(0, 1)$. Para cada método se verificó la media muestral y la varianza muestral contra los valores teóricos esperados.

Resultados numéricos

Método	Media teórica	Media muestral	Varianza teórica	Varianza muestral
Límite central	0.0000	0.0606	1.0000	0.9953
Von Neumann	0.0000	0.0212	1.0000	1.0338

Cuadro 2: Comparación de resultados entre métodos de generación normal

Ambos métodos obtuvieron un resultado OK, con errores en la media inferiores al 10 % y errores en la varianza inferiores al 15 %. El método de Von Neumann presentó un error en la media de 0.02 % y un error en la varianza de 3.38 %, mientras que el método del límite central presentó un error en la media de 0.06 % y un error en la varianza de 0.47 %.

Resultados gráficos




Figura 4: Histograma de valores generados mediante el método del límite central con $EX = 0$ y $VX = 1$.




Figura 5: Histograma de valores generados mediante el método de rechazo de Von Neumann con $EX = 0$ y $VX = 1$.

En ambos histogramas se observa la forma de campana característica de la distribución normal, con los valores concentrados alrededor de la media teórica. Las líneas verticales muestran la coincidencia entre la media muestral y la media teórica en ambos casos.

Ambos procedimientos permitieron generar muestras compatibles con una distribución normal estándar, obteniendo medias y varianzas cercanas a los valores teóricos.

El método del límite central presenta la ventaja de ser simple de implementar y computacionalmente rápido, ya que únicamente requiere la suma de variables uniformes. Sin embargo, constituye una aproximación basada en el Teorema del Límite Central y presenta limitaciones en las colas de la distribución, debido a que los valores generados quedan acotados aproximadamente al intervalo $\pm 6\sigma$.

Por su parte, el método de rechazo de Von Neumann genera valores que siguen la distribución normal estándar sin recurrir a aproximaciones del Teorema del Límite Central. Como contrapartida, requiere iteraciones adicionales debido al proceso de aceptación y rechazo, lo que incrementa el tiempo de cómputo. No obstante, reproduce de manera más precisa el comportamiento de las colas de la distribución.

En consecuencia, el método del límite central resulta adecuado cuando se busca simplicidad y velocidad de ejecución, mientras que el método de Von Neumann es preferible cuando se requiere una representación más fiel de la distribución normal teórica.

4. Distribuciones Discretas

4.1. Distribución de Pascal (o Binomial Negativa)

4.1.1. Definición teórica y parámetros

La distribución de Pascal modela el número de fracasos que ocurren en una sucesión de pruebas independientes antes de lograr exactamente k éxitos. Los valores generados coinciden con la suma de k valores de variables aleatorias con distribución geométrica. El valor k debe ser un número entero.

Ejemplos típicos en sistemas son: la cantidad de paquetes de red perdidos antes de recibir k paquetes, o la cantidad de intentos fallidos de conexión a una base de datos antes de establecer k sesiones exitosas.

Para que una variable aleatoria X siga una distribución de Pascal, deben cumplirse las condiciones de los ensayos de Bernoulli:

- El experimento consta de ensayos aleatorios e independientes.
- Cada ensayo tiene solo dos resultados posibles: éxito o fracaso.
- La probabilidad de éxito (p) es constante a lo largo de toda la sucesión de ensayos.

Parámetros:

- k : Número total de éxitos (debe ser un número entero mayor a 0).
- p : Probabilidad de éxito en un ensayo individual ($0 \leq p \leq 1$).
- q : Probabilidad de fracaso ($q = 1 - p$).

Función de probabilidad:

Dado que es una distribución discreta, su probabilidad está dada por:

$$f(x) = \binom{k+x-1}{x} p^k q^x, \quad x = 0, 1, 2, \dots \quad (31)$$

(donde x es el número de fracasos que ocurren antes de obtener k éxitos).

Valor esperado y varianza:

$$EX = \frac{kq}{p}, \quad VX = \frac{kq}{p^2} = \frac{EX}{p} \quad (32)$$

Sobredispersión y relación de parámetros:

Se puede observar que al dividir el valor esperado EX por una probabilidad p , el resultado es que la varianza será siempre mayor que la media ($VX > EX$). Esta característica se denomina *sobredispersión*.

Además, si en un estudio solo se conocen la media y la varianza empíricas, los parámetros de la distribución pueden despejarse directamente:

$$p = \frac{EX}{VX}, \quad k = \frac{(EX)^2}{VX - EX} \quad (33)$$

4.1.2. Transformada Inversa

Para la distribución de Pascal es mucho más eficiente utilizar la suma de sus componentes.

Sabiendo que un valor de Pascal equivale a la suma de k valores con distribución geométrica, y que la distribución geométrica es $x = \frac{\ln(r)}{\ln(q)}$, podemos aplicar propiedades de los logaritmos:

$$x = \frac{\sum_{i=1}^k \ln(r_i)}{\ln(q)} = \frac{\ln\left(\prod_{i=1}^k r_i\right)}{\ln(q)} \quad (34)$$

Entonces, para generar un valor con distribución de Pascal a partir de distribuciones uniformes, generamos k números pseudoaleatorios uniformes ($r_1, r_2, \dots, r_k$), multiplicarlos entre sí, aplicar la fórmula y truncar el resultado:

$$x = \left\lfloor \frac{\ln(r_1 \cdot r_2 \cdot \dots \cdot r_k)}{\ln(q)} \right\rfloor \quad (35)$$

(Se redondea debido a que son distribuciones discretas).

4.2. Distribución Binomial

4.2.1. Definición teórica y parámetros

La distribución binomial modela la cantidad de éxitos x que se obtienen al repetir n veces, en forma independiente, un experimento de Bernoulli en el que la probabilidad de éxito p es constante en cada ensayo. A diferencia de la distribución de Pascal —que cuenta los fracasos antes de alcanzar un número fijo de éxitos—, la binomial fija de antemano el número de ensayos n y deja como variable aleatoria a la cantidad de éxitos obtenidos. Este modelo resulta de gran utilidad en el muestreo estadístico y en el control de calidad, particularmente cuando el muestreo se realiza con reposición o cuando la población de la que se extraen los elementos es lo suficientemente grande como para que la probabilidad de éxito se mantenga prácticamente constante entre extracciones.

Para que una variable aleatoria X siga una distribución binomial deben cumplirse las condiciones propias de los ensayos de Bernoulli:

- El experimento consta de n ensayos idénticos e independientes.
- Cada ensayo tiene sólo dos resultados posibles: éxito o fracaso.
- La probabilidad de éxito p es constante a lo largo de los n ensayos.

Parámetros:

- n : número de ensayos (entero positivo).
- p : probabilidad de éxito en un ensayo individual, $0 \leq p \leq 1$.
- q : probabilidad de fracaso, $q = 1 - p$.

Función de probabilidad:

$$f(x) = \binom{n}{x} p^x q^{n-x}, \quad x = 0, 1, 2, \dots, n \quad (36)$$

Valor esperado y varianza:

$$EX = np, \quad VX = npq \quad (37)$$

A diferencia de la distribución de Pascal, aquí la varianza siempre resulta *menor* que la media, ya que $q < 1$. Cuando sólo se conocen la media y la varianza empíricas del fenómeno, los parámetros p y n pueden despejarse directamente:

$$p = \frac{EX - VX}{EX}, \quad n = \frac{(EX)^2}{EX - VX} \quad (38)$$

4.2.2. Transformada Inversa

La distribución binomial no posee una función de distribución acumulada $F(x)$ con una expresión cerrada e invertible analíticamente, ya que la suma $\sum \binom{n}{k} p^k q^{n-k}$ no admite una inversión algebraica directa. Por este motivo se recurre al método general de la transformada inversa para variables discretas, descrito en la Sección 2.3.1 y empleado de la misma forma para la distribución Empírica Discreta: se acumulan las probabilidades puntuales $f(x)$ hasta encontrar el primer valor de x para el cual la probabilidad acumulada $F(x)$ iguala o supera al número aleatorio r generado.

El procedimiento es el siguiente:

1. Generar $r \sim U(0, 1)$.
2. Calcular $f(x) = \binom{n}{x} p^x q^{n-x}$ para $x = 0, 1, \dots, n$, acumulando $F(x) = \sum_{k=0}^x f(k)$.
3. Retornar el menor valor de x tal que $r \leq F(x)$.

Ejemplo numérico: sea $n = 5$, $p = 0,4$ y $r = 0,65$:

El valor generado es $x = 2$.

4.2.3. Testeo y resultados

Se generaron 1000 valores con los parámetros $n = 10$ (cantidad de ensayos) y $p = 0,4$ (probabilidad de éxito). Los resultados numéricos obtenidos fueron:

x	$f(x)$	$F(x)$	$ir \leq F(x)?$
0	0,0778	0,0778	No
1	0,2592	0,3370	No
2	0,3456	0,6826	Sí $\rightarrow x = 2$

Cuadro 3: Ejemplo de generación de un valor binomial mediante transformada inversa ($n = 5$, $p = 0,4$, $r = 0,65$).

	Teórico	Muestral
Media (EX)	4,0000	3,9910 (error: 0,22 %)
Varianza (VX)	2,4000	2,4829 (error: 3,45 %)

Cuadro 4: Comparación de momentos — Binomial($n = 10$, $p = 0,4$), 1000 valores generados.

Ambos errores se encuentran ampliamente dentro de los márgenes aceptables (10 % para la media y 15 % para la varianza), confirmando el correcto funcionamiento del generador. El gráfico de la Figura 6 muestra que las frecuencias relativas observadas siguen de cerca la forma de la distribución teórica en todo el rango de valores posibles ($x = 0, \dots, 10$), con la mayor concentración de frecuencias en torno a $x = 4$, tal como predice la media teórica.




Figura 6: Frecuencias observadas vs. teóricas — Binomial($n = 10$, $p = 0,4$), 1000 valores generados.

4.3. Distribución Hipergeométrica

4.3.1. Definición teórica y parámetros

La distribución hipergeométrica modela la cantidad de elementos de una clase determinada que se obtienen al extraer, *sin reemplazo*, una muestra de tamaño n de una población finita de N elementos. La población está dividida en dos clases: Np elementos pertenecientes a la clase I y Nq elementos pertenecientes a la clase II, con $p + q = 1$. Es el análogo de la distribución binomial para el caso de muestreo sin reposición, y se utiliza ampliamente en control de calidad y control de producción, por ejemplo al inspeccionar un lote finito de piezas para determinar cuántas resultan defectuosas.

A diferencia de la binomial, en este caso la probabilidad de éxito *no* se mantiene constante entre extracciones, ya que cada elemento retirado modifica la composición de la población restante. Cuando N es grande en relación con n , este efecto se vuelve despreciable y la distribución hipergeométrica tiende a la binomial.

Parámetros:

- N : tamaño de la población (entero positivo).
- n : tamaño de la muestra extraída sin reemplazo, $n < N$.
- p : proporción de elementos de la clase I en la población (Np debe ser entero).
- $q = 1 - p$: proporción de elementos de la clase II.

Función de probabilidad:

$$f(x) = \frac{\binom{Np}{x} \binom{Nq}{n-x}}{\binom{N}{n}}, \quad 0 \leq x \leq Np, \quad 0 \leq n-x \leq Nq \quad (39)$$

Valor esperado y varianza:

$$EX = np, \quad VX = npq \left(\frac{N-n}{N-1} \right) \quad (40)$$

El factor $(N-n)/(N-1)$ se conoce como *factor de corrección para población finita*: a medida que $N \rightarrow \infty$ con n fijo, este factor tiende a 1 y la varianza hipergeométrica converge a la varianza binomial npq , lo cual confirma que el muestreo sin reposición de una población muy grande se comporta, en la práctica, como un muestreo con reposición.

4.3.2. Transformada Inversa

Al igual que en el caso binomial, $F(x)$ no posee una forma cerrada invertible analíticamente, por lo que se aplica el mismo método general de la transformada inversa discreta: se acumulan las probabilidades puntuales $f(x)$ —calculadas mediante los coeficientes combinatorios definidos anteriormente— hasta encontrar el primer valor de x que satisface $r \leq F(x)$.

El procedimiento es el siguiente:

1. Generar $r \sim U(0, 1)$.
2. Calcular $f(x) = \frac{\binom{Np}{x} \binom{Nq}{n-x}}{\binom{N}{n}}$ para los valores válidos de x (es decir, $\max(0, n - Nq) \leq x \leq \min(n, Np)$), acumulando $F(x) = \sum_{k=0}^x f(k)$.
3. Retornar el menor valor de x tal que $r \leq F(x)$.

Ejemplo numérico: sea una población de $N = 20$ elementos, de los cuales $Np = 8$ pertenecen a la clase I ($p = 0,4$); se extrae sin reemplazo una muestra de $n = 5$ elementos y se genera $r = 0,5$:

x	$f(x)$	$F(x)$	$r \leq F(x)?$
0	0,0511	0,0511	No
1	0,2554	0,3065	No
2	0,3973	0,7038	Sí $\rightarrow x = 2$

Cuadro 5: Ejemplo de generación de un valor hipergeométrico mediante transformada inversa ($N = 20$, $Np = 8$, $n = 5$, $r = 0,5$).

El valor generado es $x = 2$.

4.4. Distribución de Poisson

4.4.1. Definición teórica y parámetros

La distribución de Poisson modela la cantidad de eventos que ocurren en un intervalo de tiempo o espacio fijo, bajo las condiciones de que los eventos son independientes entre sí, ocurren a una tasa constante y es extremadamente improbable que dos ocurran simultáneamente. Ejemplos típicos son: la cantidad de aviones que aterrizan en un aeropuerto en un período dado, el número de llamadas recibidas en una central telefónica por hora, o la cantidad de fallas de una máquina por mes.

Para que una variable aleatoria X siga una distribución de Poisson, deben cumplirse las siguientes condiciones:

1. El número de eventos en un intervalo es independiente del número de eventos en cualquier otro intervalo no superpuesto.
2. La probabilidad de que ocurra un evento en un intervalo corto $[t, t + \Delta t]$ es aproximadamente $\lambda \cdot \Delta t$.
3. La probabilidad de que ocurran dos o más eventos en ese intervalo tiende a cero a medida que $\Delta t \rightarrow 0$.

Parámetro: λ (lambda), con $\lambda > 0$. Representa la tasa media de ocurrencia de eventos por unidad de intervalo.

Función de probabilidad:

$$f(x) = e^{-\lambda} \frac{\lambda^x}{x!}, \quad x = 0, 1, 2, \dots \quad (41)$$

Función de distribución acumulada:

$$F(x) = \sum_{k=0}^x e^{-\lambda} \frac{\lambda^k}{k!}. \quad (42)$$

Esta suma no tiene una forma cerrada invertible, lo que impide aplicar la transformada inversa de manera directa.

Valor esperado y varianza:

$$EX = \lambda, \quad VX = \lambda. \quad (43)$$

Una propiedad notable de esta distribución es que la media y la varianza son iguales, lo cual constituye un criterio empírico para verificar si un conjunto de datos puede ajustarse al modelo de Poisson.

4.4.2. Transformada Inversa

Dado que $F(x)$ no tiene una expresión analítica invertible, la transformada inversa no puede aplicarse en su forma directa. Sin embargo, existe una relación fundamental entre la distribución de Poisson y la exponencial que permite derivar un método de generación eficiente.

Si los intervalos entre eventos sucesivos siguen una distribución exponencial de media unitaria ($t_i = -\ln r_i$, con r_i uniformes), entonces el número de eventos que ocurren antes de superar el tiempo acumulado λ sigue exactamente una distribución de Poisson con parámetro λ . En términos matemáticos, x es el mayor entero que satisface:

$$\sum_{i=0}^x t_i \leq \lambda < \sum_{i=0}^{x+1} t_i. \quad (44)$$

Tomando logaritmos y usando la identidad $\sum \ln r_i = \ln \prod r_i$, la condición (44) es equivalente a:

$$\prod_{i=0}^x r_i \geq e^{-\lambda} > \prod_{i=0}^{x+1} r_i. \quad (45)$$

Por lo tanto, x es el mayor entero tal que el producto acumulado de números uniformes no cae por debajo de $e^{-\lambda}$. El algoritmo de generación queda:

1. Calcular $B = e^{-\lambda}$. Inicializar $TR = 1$ y $x = 0$.
2. Generar $r \sim U(0, 1)$ y actualizar $TR = TR \times r$.
3. Si $TR \geq B$: incrementar $x = x + 1$ y volver al paso 2.
4. De lo contrario, retornar x .

Ejemplo numérico: sea $\lambda = 2$, entonces $B = e^{-2} \approx 0,1353$. Con los siguientes números uniformes:

Iteración	r_i	TR	$iTR \geq B?$
1	0,72	0,720	Sí $\rightarrow x = 1$
2	0,35	0,252	Sí $\rightarrow x = 2$
3	0,61	0,1537	Sí $\rightarrow x = 3$
4	0,85	0,1306	No $\rightarrow$ retornar $x = 3$

El valor generado es $x = 3$.

4.4.3. Testeo y resultados

Se generaron $n = 1000$ valores con $\lambda = 4$. Los resultados numéricos obtenidos fueron:

	Teórico	Muestral	
Media (EX)	4,0000	3,9560	(error: 1,10 %)
Varianza (VX)	4,0000	3,5701	(error: 10,75 %)

Cuadro 6: Comparación de momentos — Poisson($\lambda = 4$), $n = 1000$.

Ambos errores se encuentran dentro de los márgenes aceptables (10 % para la media y 15 % para la varianza). El gráfico de la figura 7 confirma visualmente que las frecuencias relativas observadas se ajustan correctamente a las probabilidades teóricas en todos los valores de la distribución.




Figura 7: Frecuencias observadas vs. teóricas — Poisson($\lambda = 4$), $n = 1000$.

4.5. Distribución Empírica Discreta

4.5.1. Definición teórica y parámetros

La distribución empírica discreta no corresponde a un modelo paramétrico específico, sino que representa cualquier distribución discreta definida por un conjunto finito de valores posibles y sus probabilidades asociadas, obtenidas generalmente de datos observados o estimadas por criterio experto. Se utiliza cuando no existe un modelo teórico conocido que se ajuste al fenómeno pero sí se dispone de frecuencias históricas.

Sea X una variable aleatoria discreta que toma los valores $b_1, b_2, \dots, b_n$ con probabilidades $p_1, p_2, \dots, p_n$ respectivamente, donde:

- $P(X = b_i) = p_i, \quad i = 1, 2, \dots, n.$
- $p_i \geq 0$ para todo i .
- $\sum_{i=1}^n p_i = 1.$

Función de distribución acumulada:

$$F(b_i) = P(X \leq b_i) = \sum_{k=1}^i p_k. \quad (46)$$

Esta es una función escalonada: constante entre los valores b_i y crece en saltos de magnitud p_i en cada b_i .

El valor esperado y la varianza dependen de la distribución particular que se esté modelando:

$$EX = \sum_{i=1}^n b_i p_i, \quad VX = \sum_{i=1}^n b_i^2 p_i - (EX)^2. \quad (47)$$

4.5.2. Transformada Inversa

La transformada inversa se adapta al caso discreto de la siguiente manera. Dado que $F(x)$ es escalonada, la inversa no es única; se define convencionalmente como el menor valor b_i cuya probabilidad acumulada supera o iguala a r . El procedimiento es:

1. Generar $r \sim U(0, 1)$.
2. Encontrar el índice i tal que:

$$F(b_{i-1}) < r \leq F(b_i),$$

con $F(b_0) = 0$ por convención.

3. Retornar $x = b_i$.

Equivalentemente, se recorre la lista de probabilidades acumuladas y se retorna el primer b_i para el cual $F(b_i) \geq r$.

Ejemplo: consideremos la distribución discreta del siguiente cuadro, tomado del ejemplo de Naylor (1):

Valor b_i	Probabilidad p_i	$F(b_i)$
b_1	0,273	0,273
b_2	0,037	0,310
b_3	0,195	0,505
b_4	0,009	0,514
b_5	0,124	0,638
b_6	0,058	0,696
b_7	0,062	0,758
b_8	0,151	0,909
b_9	0,047	0,956
b_{10}	0,044	1,000

Cuadro 7: Distribución empírica discreta de ejemplo (Naylor, 1982).

- Si $r = 0,45$: como $0,310 < 0,45 \leq 0,505$, se retorna $x = b_3$.
- Si $r = 0,72$: como $0,696 < 0,72 \leq 0,758$, se retorna $x = b_7$.
- Si $r = 0,10$: como $0 < 0,10 \leq 0,273$, se retorna $x = b_1$.

4.5.3. Testeo y resultados

Se generaron $n = 1000$ valores utilizando la distribución empírica del ejemplo de Naylor (1) (véase la tabla 7). El valor esperado teórico $EX = \sum b_i p_i = 4,4410$ y la varianza teórica $VX = \sum b_i^2 p_i - (EX)^2 = 8,6945$ se calcularon directamente a partir de las probabilidades definidas.

	Teórico	Muestral
Media (EX)	4,4410	4,4960 (error: 1,24 %)
Varianza (VX)	8,6945	8,4440 (error: 2,88 %)

Cuadro 8: Comparación de momentos — Empírica Discreta, $n = 1000$.

Ambos errores son menores al 3 %, lo que indica un excelente ajuste. El gráfico de la figura 8 muestra que el generador reproduce correctamente la forma irregular de la distribución, respetando las diferencias de probabilidad entre los distintos valores posibles.




Figura 8: Frecuencias observadas vs. teóricas — Empírica Discreta, $n = 1000$.

Referencias

- [1] Naylor, T. H. *Técnicas de Simulación en Computadoras*. Editorial Limusa, 1982.
- [2] Python Software Foundation. *random* — Generate pseudo-random numbers. Disponible en: <https://docs.python.org/3/library/random.html>
- [3] Matplotlib Development Team. *Matplotlib Documentation*. Disponible en: <https://matplotlib.org/stable/index.html>
- [4] Cátedra de Simulación. *Material teórico de la materia*. Universidad Tecnológica Nacional — FRRO, 2026.